

第七章 参数估计

参数估计的知识架构

参数估计

├── 点估计

│ ├── 矩估计

│ ├── 最大似然估计

│ └── 估计量的性质

│ ├── 无偏性

│ ├── 有效性

│ └── 相合性

└── 区间估计

│ ├── 置信区间的定义

│ ├── 枢轴量思想

│ ├── 常见参数的区间估计

│ └── 置信水平与区间长度

1 点估计 (Point Estimation)

目标:

用一个**统计量 (单个数值) **来估计未知参数。

(1) 基本思想

- 设总体分布含未知参数 θ
- 从样本 X_1, \dots, X_n 构造统计量 $\hat{\theta} = g(X_1, \dots, X_n)$
- 用 $\hat{\theta}$ 作为 θ 的估计值

(2) 常见点估计方法 (重点)

1. 矩估计 (Method of Moments)

- 用样本矩代替理论矩
- 思想直观, 计算简单

2. 最大似然估计 (Maximum Likelihood Estimation, MLE)

- 选择使样本出现概率最大的参数值
- 理论地位最高、应用最广

2 区间估计 (Interval Estimation)

目标:

给出一个**区间**，并说明参数落在该区间内的**可信程度**。

(1) 置信区间的基本形式

$$P(\theta \in [L(X), U(X)]) = 1 - \alpha$$

- $[L, U]$: 置信区间
- $1 - \alpha$: 置信水平 (如 95%、99%)

(2) 常见置信区间类型

• 均值的置信区间

- 正态总体 (σ 已知 / 未知)
- 大样本近似 (CLT)

• 方差的置信区间

- 基于 χ^2 分布

• 比例参数的置信区间

• 参数函数的置信区间

(3) 构造方法 (核心思想)

- 枢轴量法 (pivot)
- 利用已知分布 (正态 / t / χ^2 / F)



区间估计回答的是:

“我们对这个估计有多大把握?”

第一节 点估计

一、点估计问题的提法

二、估计量的求法

三、小结

一、点估计问题的提法

设总体 X 的分布函数形式已知, 但它的一个或多个参数为未知, 借助于总体 X 的一个样本来估计总体未知参数的值的问题称为点估计问题.

例1 在某炸药制造厂, 一天中发生着火现象的次数 X 是一个随机变量, 假设它服从以 $\lambda > 0$ 为参数的泊松分布, 参数 λ 为未知, 设有以下的样本值, 试估计参数 λ .

着火次数 k	0	1	2	3	4	5	6	
发生 k 次着 火的天数 n_k	75	90	54	22	6	2	1	$\Sigma = 250$

解 因为 $X \sim \pi(\lambda)$, 所以 $\lambda = E(X)$.

用样本均值来估计总体的均值 $E(X)$.

$$\bar{x} = \frac{\sum_{k=0}^6 kn_k}{\sum_{k=0}^6 n_k} = \frac{1}{250} (0 \times 75 + 1 \times 90 + 2 \times 54 + 3 \times 22 + 4 \times 6 + 5 \times 2 + 6 \times 1) = 1.22.$$

故 $E(X) = \lambda$ 的估计为 1.22 .

点估计问题的一般提法（定义）

设总体 X 的分布函数 $F(x; \theta)$ 的形式为已知, θ 是待估参数. X_1, X_2, \dots, X_n 是 X 的一个样本, x_1, x_2, \dots, x_n 为相应的一个样本值.

点估计问题就是要构造一个适当的统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$, 用它的观察值 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 来估计未知参数 θ .

$\hat{\theta}(X_1, X_2, \dots, X_n)$ 称为 θ 的估计量. } 通称估计,
 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 称为 θ 的估计值. } 简记为 $\hat{\theta}$.

二、估计量的求法

由于估计量是样本的函数, 是随机变量, 故对不同的样本值, 得到的参数值往往不同, 如何求估计量是关键问题.

常用构造估计量的方法: (两种)

矩估计法和最大似然估计法.



1. 矩估计法

设 X 为连续型随机变量, 其概率密度为 $f(x; \theta_1, \theta_2, \dots, \theta_k)$, 或 X 为离散型随机变量, 其分布律为 $P\{X = x\} = p(x; \theta_1, \theta_2, \dots, \theta_k)$, 其中 $\theta_1, \theta_2, \dots, \theta_k$ 为待估参数, 若 X_1, X_2, \dots, X_n 为来自 X 的样本, 假设总体 X 的前 k 阶矩存在, 且均为 $\theta_1, \theta_2, \dots, \theta_k$ 的函数, 即



$$\mu_l = E(X^l) = \int_{-\infty}^{+\infty} x^l f(x; \theta_1, \theta_2, \dots, \theta_k) dx \quad (X \text{ 为连续型})$$

$$\text{或 } \mu_l = E(X^l) = \sum_{x \in R_X} x^l p(x; \theta_1, \theta_2, \dots, \theta_k), \quad (X \text{ 为离散型})$$

其中 R_X 是 x 可能取值的范围, $l = 1, 2, \dots, k$

因为样本矩 $A_l = \frac{1}{n} \sum_{i=1}^n X_i^l$ 依概率收敛于相应的

总体矩 μ_l ($l = 1, 2, \dots, k$),

样本矩的连续函数依概率收敛于相应的总体矩的连续函数.

矩估计法的定义

用样本矩来估计总体矩,用样本矩的连续函数来估计总体矩的连续函数,这种估计法称为**矩估计法**.

矩估计法的具体做法: 令 $\mu_l = A_l, \quad l = 1, 2, \dots, k.$

这是一个包含 k 个未知参数 $\theta_1, \theta_2, \dots, \theta_k$ 的方程组, 解出其中 $\theta_1, \theta_2, \dots, \theta_k$.

用方程组的解 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 分别作为 $\theta_1, \theta_2, \dots, \theta_k$ 的估计量, 这个估计量称为矩估计量.

矩估计量的观察值称为矩估计值.

例3 设总体 X 在 $[0, \theta]$ 上服从均匀分布, 其中 θ ($\theta > 0$) 未知, (X_1, X_2, \dots, X_n) 是来自总体 X 的样本, 求 θ 的估计量.

解 因为 $\mu_1 = E(X) = \frac{\theta}{2}$,

根据矩估计法, 令 $\frac{\hat{\theta}}{2} = A_1 = \bar{X}$,

所以 $\hat{\theta} = 2\bar{X}$ 为所求 θ 的估计量.

例4 设总体 X 在 $[a, b]$ 上服从均匀分布, 其中 a, b 未知, (X_1, X_2, \dots, X_n) 是来自总体 X 的样本, 求 a, b 的估计量.

解 $\mu_1 = E(X) = \frac{a+b}{2},$

$$\mu_2 = E(X^2) = D(X) + [E(X)]^2 = \frac{(a-b)^2}{12} + \frac{(a+b)^2}{4},$$

$$\text{令 } \frac{a+b}{2} = A_1 = \frac{1}{n} \sum_{i=1}^n X_i,$$

$$\frac{(a-b)^2}{12} + \frac{(a+b)^2}{4} = A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2,$$

$$\text{即} \begin{cases} a + b = 2A_1, \\ b - a = \sqrt{12(A_2 - A_1^2)}. \end{cases}$$

解方程组得到 a, b 的矩估计量分别为

$$\hat{a} = A_1 - \sqrt{3(A_2 - A_1^2)} = \bar{X} - \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2},$$
$$\hat{b} = A_1 + \sqrt{3(A_2 - A_1^2)} = \bar{X} + \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2}.$$

例5 设总体 X 服从几何分布, 即有分布律

$$P\{X = k\} = p(1-p)^{k-1} \quad (k = 1, 2, \cdots),$$

其中 p ($0 < p < 1$) 未知, (X_1, X_2, \cdots, X_n) 是来自总体 X 的样本, 求 p 的估计量.

解

$$\mu_1 = E(X) = \sum_{k=1}^{\infty} k p (1-p)^{k-1} = \frac{1}{p},$$

$$\text{令 } \frac{1}{\hat{p}} = A_1 = \bar{X},$$

所以 $\hat{p} = \frac{1}{\bar{X}}$ 为所求 p 的估计量.

例6 设总体 X 的均值 μ 和方差 σ^2 都存在, 且有 $\sigma^2 > 0$, 但 μ 和 σ^2 均为未知, 又设 X_1, X_2, \dots, X_n 是一个样本, 求 μ 和 σ^2 的矩估计量.

解

$$\mu_1 = E(X) = \mu,$$
$$\mu_2 = E(X^2) = D(X) + [E(X)]^2 = \sigma^2 + \mu^2,$$
$$\text{令 } \begin{cases} \hat{\mu} = A_1, \\ \hat{\sigma}^2 + \hat{\mu}^2 = A_2. \end{cases}$$

解方程组得到矩估计量分别为 $\hat{\mu} = A_1 = \bar{X},$

$$\hat{\sigma}^2 = A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

上例表明:

总体均值与方差的矩估计量的表达式不因不同的总体分布而异.

例 $X \sim N(\mu, \sigma^2)$, μ, σ^2 未知, 即得 μ, σ^2 的矩估计量

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

一般地,

用样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 作为总体 X 的均值的矩估计,

用样本二阶中心矩 $B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 作为总体

X 的方差的矩估计.

2. 最大似然估计法

(1) 设总体 X 属离散型

似然函数的定义

设分布律 $P\{X = k\} = p(x; \theta)$, θ 为待估参数, $\theta \in \Theta$,

(其中 Θ 是 θ 可能的取值范围)

X_1, X_2, \dots, X_n 是来自总体 X 的样本,

则 X_1, X_2, \dots, X_n 的联合分布律为 $\prod_{i=1}^n p(x_i; \theta)$.

又设 x_1, x_2, \dots, x_n 为相应于样本 X_1, X_2, \dots, X_n 的一个样本值.

则样本 X_1, X_2, \dots, X_n 取到观察值 x_1, x_2, \dots, x_n 的概率, 即事件 $X_1 = x_1, X_2 = x_2, \dots, X_n = x_n$ 发生的概率为

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta), \quad \theta \in \Theta,$$

$L(\theta)$ 称为样本似然函数

最大似然估计法

得到样本值 x_1, x_2, \dots, x_n 时, 选取使似然函数 $L(\theta)$

取得最大值的 $\hat{\theta}$ 作为未知参数 θ 的估计值,

即 $L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$.

(其中 Θ 是 θ 可能的取值范围)

这样得到的 $\hat{\theta}$ 与样本值 x_1, x_2, \dots, x_n 有关, 记为

$\hat{\theta}(x_1, x_2, \dots, x_n)$, 参数 θ 的最大似然估计值,

$\hat{\theta}(X_1, X_2, \dots, X_n)$ 参数 θ 的最大似然估计量

(2) 设总体 X 属连续型

似然函数的定义

设概率密度为 $f(x; \theta)$, θ 为待估参数, $\theta \in \Theta$,

(其中 Θ 是 θ 可能的取值范围)

X_1, X_2, \dots, X_n 是来自总体 X 的样本,

则 X_1, X_2, \dots, X_n 的联合密度为 $\prod_{i=1}^n f(x_i; \theta)$.

又设 x_1, x_2, \dots, x_n 为相应于样本 X_1, X_2, \dots, X_n 的一个样本值.

则随机点 (X_1, X_2, \dots, X_n) 落在点 (x_1, x_2, \dots, x_n) 的邻域(边长分别为 dx_1, dx_2, \dots, dx_n 的 n 维立方体)内的概率近似地为 $\prod_{i=1}^n f(x_i; \theta) dx_i$,

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta),$$

$L(\theta)$ 称为样本的似然函数.

若 $L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$.

$\hat{\theta}(x_1, x_2, \dots, x_n)$ 参数 θ 的最大似然估计值,

$\hat{\theta}(X_1, X_2, \dots, X_n)$ 参数 θ 的最大似然估计量

最大似然估计法是由费舍尔引进的.

求最大似然估计量的步骤:

(一) 写出似然函数

$$L(\theta) = L(x_1, x_2, \cdots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta)$$

$$\text{或 } L(\theta) = L(x_1, x_2, \cdots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta);$$

(二) 取对数

$$\ln L(\theta) = \sum_{i=1}^n \ln p(x_i; \theta) \quad \text{或} \quad \ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta);$$

(三) 对 θ 求导 $\frac{d \ln L(\theta)}{d \theta}$, 并令 $\frac{d \ln L(\theta)}{d \theta} = 0$, 对数似然方程

解方程即得未知参数 θ 的最大似然估计值 $\hat{\theta}$.

最大似然估计法也适用于分布中含有多个未知参数的情况. 此时只需令

$$\frac{\partial}{\partial \theta_i} \ln L = 0, \quad i = 1, 2, \dots, k. \quad \text{对数似然方程组}$$

解出由 k 个方程组成的方程组, 即可得各未知参数 θ_i ($i = 1, 2, \dots, k$) 的最大似然估计值 $\hat{\theta}_i$.

例7 设 $X \sim B(1, p)$, X_1, X_2, \dots, X_n 是来自 X 的一个样本, 求 p 的最大似然估计量.

解 设 x_1, x_2, \dots, x_n 为相应于样本 X_1, X_2, \dots, X_n 的一个样本值,

X 的分布律为 $P\{X = x\} = p^x (1-p)^{1-x}, x = 0, 1,$

似然函数
$$L(p) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i}$$
$$= p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i},$$

$$\ln L(p) = \left(\sum_{i=1}^n x_i \right) \ln p + \left(n - \sum_{i=1}^n x_i \right) \ln(1-p),$$

$$\text{令 } \frac{d}{dp} \ln L(p) = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} = 0,$$

$$\text{解得 } p \text{ 的最大似然估计值 } p = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

$$p \text{ 的最大似然估计量为 } \hat{p} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$$

这一估计量与矩估计量是相同的.

例8 设 X 服从参数为 λ ($\lambda > 0$) 的泊松分布, X_1, X_2, \dots, X_n 是来自 X 的一个样本, 求 λ 的最大似然估计量.

解 因为 X 的分布律为

$$P\{X = x\} = \frac{\lambda^x}{x!} e^{-\lambda}, \quad (x = 0, 1, 2, \dots, n)$$

所以 λ 的似然函数为

$$L(\lambda) = \prod_{i=1}^n \left(\frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \right) = e^{-n\lambda} \frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n (x_i!)},$$

$$\ln L(\lambda) = -n\lambda + \left(\sum_{i=1}^n x_i\right) \ln \lambda - \sum_{i=1}^n \ln(x_i!),$$

$$\text{令 } \frac{\mathrm{d}}{\mathrm{d}\lambda} \ln L(\lambda) = -n + \frac{\sum_{i=1}^n x_i}{\lambda} = 0,$$

$$\text{解得 } \lambda \text{ 的最大似然估计值 } \lambda = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x},$$

$$\lambda \text{ 的最大似然估计量为 } \hat{\lambda} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$$

这一估计量与矩估计量是相同的.

例9 设总体 $X \sim N(\mu, \sigma^2)$, μ, σ^2 为未知参数, x_1, x_2, \dots, x_n 是来自 X 的一个样本值, 求 μ 和 σ^2 的最大似然估计量.

解 X 的概率密度为

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}},$$

X 的似然函数为

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}},$$

$$\ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 ,$$

$$\text{令} \begin{cases} \frac{\partial}{\partial \mu} \ln L(\mu, \sigma^2) = 0, \\ \frac{\partial}{\partial \sigma^2} \ln L(\mu, \sigma^2) = 0, \end{cases}$$

$$\begin{cases} \frac{1}{\sigma^2} \left[\sum_{i=1}^n x_i - n\mu \right] = 0, \\ -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0, \end{cases}$$

$$\text{由 } \frac{1}{\sigma^2} \left[\sum_{i=1}^n x_i - n\mu \right] = 0 \text{ 解得 } \hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x},$$

$$\text{由 } -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0 \text{ 解得}$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2,$$

故 μ 和 σ^2 的最大似然估计量分别为

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2. \quad \text{它们与相应的矩估计量相同.}$$

例10 设总体 X 在 $[a, b]$ 上服从均匀分布, 其中 a, b 未知, x_1, x_2, \dots, x_n 是来自总体 X 的一个样本值, 求 a, b 的最大似然估计量.

解 记 $x_{(l)} = \min(x_1, x_2, \dots, x_n),$

$$x_{(h)} = \max(x_1, x_2, \dots, x_n),$$

X 的概率密度为

$$f(x; a, b) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{其他.} \end{cases}$$



因为 $a \leq x_1, x_2, \dots, x_n \leq b$ 等价于 $a \leq x_{(l)}, x_{(h)} \leq b$,
作为 a, b 的函数的似然函数为

$$L(a, b) = \begin{cases} \frac{1}{(b-a)^n}, & a \leq x_{(l)}, b \geq x_{(h)}, \\ 0, & \text{其他} \end{cases}$$

于是对于满足条件 $a \leq x_{(l)}, b \geq x_{(h)}$ 的任意 a, b 有

$$L(a, b) = \frac{1}{(b-a)^n} \leq \frac{1}{(x_{(h)} - x_{(l)})^n},$$

即似然函数 $L(a, b)$ 在 $a = x_{(l)}$, $b = x_{(h)}$ 时
取到最大值 $(x_{(h)} - x_{(l)})^{-n}$,

a, b 的最大似然估计值

$$\hat{a} = x_{(l)} = \min_{1 \leq i \leq n} x_i, \quad \hat{b} = x_{(h)} = \max_{1 \leq i \leq n} x_i,$$

a, b 的最大似然估计量

$$\hat{a} = \min_{1 \leq i \leq n} X_i, \quad \hat{b} = \max_{1 \leq i \leq n} X_i .$$

最大似然估计的性质

不变性

设 θ 的函数 $u = u(\theta)$, $\theta \in \Theta$ 具有单值反函数 $\theta = \theta(u)$, $u \in U$. 又设 $\hat{\theta}$ 是 X 的概率密度函数 $f(x; \theta)$ (f 形式已知) 中的参数 θ 的最大似然估计, 则 $\hat{u} = u(\hat{\theta})$ 是 $u(\theta)$ 的最大似然估计.

证明 因为 $\hat{\theta}$ 是 θ 的最大似然估计值,
所以 $L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta),$

其中 x_1, x_2, \dots, x_n 是来自总体 X 的一个样本值,

由于 $\hat{u} = u(\hat{\theta}), \quad \hat{\theta} = \theta(\hat{u}),$

故 $L(x_1, x_2, \dots, x_n; \theta(\hat{u})) = \max_{u \in I} L(x_1, x_2, \dots, x_n; \theta(u))$,

于是 $\hat{u} = u(\hat{\theta})$ 是 $u(\theta)$ 的最大似然估计.

此性质可以推广到总体分布中含有多个未知参数的情况.

如例9中 σ^2 的最大似然估计值为 $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$,

函数 $u = u(\sigma^2) = \sqrt{\sigma^2}$ 有单值反函数 $\sigma^2 = u^2 (u \geq 0)$,

故标准差 σ 的最大似然估计值为

$$\hat{\sigma} = \sqrt{\hat{\sigma}^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}.$$

三、小结

两种求点估计的方法: $\left\{ \begin{array}{l} \text{矩估计法} \\ \text{最大似然估计法} \end{array} \right.$

在统计问题中往往先使用最大似然估计法,
在最大似然估计法使用不方便时, 再用矩估计法.

$$\text{似然函数 } L(\theta) = L(x_1, x_2, \cdots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta)$$

$$\text{或 } L(\theta) = L(x_1, x_2, \cdots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta);$$

随堂练习

9. 设总体 X 的概率密度为

$$f(x; \theta) = \begin{cases} \frac{1}{1-\theta}, & \theta \leq x \leq 1, \\ 0, & \text{其他,} \end{cases}$$

其中 $0 < \theta < 1$ 为未知参数, X_1, X_2, \dots, X_n 为来自该总体的简单随机样本。

- (1) 求 θ 的矩估计量 $\hat{\theta}_1$;
- (2) 求 θ 的最大似然估计量 $\hat{\theta}_2$ 。

解:

(1) 计算矩估计量:

$$E(X) = \int_{\theta}^1 x \frac{1}{1-\theta} dx = \frac{1-\theta^2}{2(1-\theta)} = \frac{1+\theta}{2}.$$

令 $E(X) = \bar{X}$, 得

$$\hat{\theta}_1 = 2\bar{X} - 1.$$

(2) 最大似然估计量:

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta) = \left(\frac{1}{1-\theta} \right)^n \mathbf{1}\{\theta \leq x_{(1)}\},$$

其中 $x_{(1)} = \min\{X_1, \dots, X_n\}$ 。

在 $\theta \leq x_{(1)}$ 上,

$$\ln L(\theta) = -n \ln(1-\theta), \quad \frac{d}{d\theta} \ln L(\theta) = \frac{n}{1-\theta} > 0,$$

故 $\ln L(\theta)$ 随 θ 单调递增, 在可行区间右端取得最大值:

$$\hat{\theta}_2 = x_{(1)}.$$

随堂练习

10. 设总体 X 的概率密度为

$$f(x; \theta) = \begin{cases} \frac{\theta^2}{x^3} e^{-\theta/x}, & x > 0, \\ 0, & \text{其他,} \end{cases}$$

其中 $\theta > 0$ 为未知参数, X_1, X_2, \dots, X_n 为来自总体 X 的简单随机样本。

- (1) 求 θ 的矩估计量;
- (2) 求 θ 的最大似然估计量。

解:

(1) 计算矩估计量:

$$E(X) = \int_0^{\infty} x \frac{\theta^2}{x^3} e^{-\theta/x} dx = \theta.$$

因而

$$\hat{\theta}_1 = \bar{X}.$$

(2) 最大似然估计量:

似然函数为

$$L(\theta) = \prod_{i=1}^n \frac{\theta^2}{x_i^3} e^{-\theta/x_i} = \frac{\theta^{2n}}{\prod_{i=1}^n x_i^3} \exp\left(-\theta \sum_{i=1}^n \frac{1}{x_i}\right).$$

对数似然

$$\ln L(\theta) = 2n \ln \theta - 3 \sum_{i=1}^n \ln x_i - \theta \sum_{i=1}^n \frac{1}{x_i}.$$

求导并令其为零:

$$\frac{d}{d\theta} \ln L(\theta) = \frac{2n}{\theta} - \sum_{i=1}^n \frac{1}{x_i} = 0$$

解得

$$\hat{\theta}_2 = \frac{2n}{\sum_{i=1}^n \frac{1}{x_i}}.$$

随堂练习

11. 设总体 X 的概率密度为

$$f(x; \theta) = \begin{cases} \frac{\theta}{2}, & 0 < x < 2, \\ \frac{1}{2} - \frac{\theta}{2}, & 2 \leq x \leq 4, \\ 0, & \text{其他}, \end{cases}$$

其中 $0 < \theta < 2$ 为未知参数。 X_1, X_2, \dots, X_n 为来自总体 X 的简单随机样本，记 k 为样本值 x_1, x_2, \dots, x_n 中小于 2 的个数。

- (1) 求 θ 的矩估计量；
- (2) 求 θ 的最大似然估计量。

解:

(1) 计算矩估计量:

$$\begin{aligned} E(X) &= \int_0^2 x \frac{\theta}{2} dx + \int_2^4 x \left(\frac{1}{2} - \frac{\theta}{2} \right) dx \\ &= \frac{\theta}{2} \cdot \frac{2^2}{2} + \left(\frac{1}{2} - \frac{\theta}{2} \right) \cdot \frac{4^2 - 2^2}{2} \\ &= 3 - 2\theta. \end{aligned}$$

令 $E(X) = \bar{X}$, 得

$$\hat{\theta}_1 = \frac{3 - \bar{X}}{2}.$$

(2) 最大似然估计量:

若有 k 个样本落在 $(0, 2)$ 内, 其余 $n - k$ 个落在 $[2, 4]$ 内, 则

$$L(\theta) = \left(\frac{\theta}{2} \right)^k \left(\frac{1}{2} - \frac{\theta}{2} \right)^{n-k} = \left(\frac{\theta}{2} \right)^k \left(\frac{1-\theta}{2} \right)^{n-k}.$$

对数似然

$$\ln L(\theta) = k \ln \theta + (n - k) \ln(1 - \theta) + \text{常数}.$$

求导并令其为零:

$$\frac{k}{\theta} - \frac{n - k}{1 - \theta} = 0 \quad \Rightarrow \quad \hat{\theta}_2 = \frac{k}{n}.$$

由 $0 \leq k \leq n$ 可知 $0 \leq \hat{\theta}_2 \leq 1 < 2$, 满足参数空间 $0 < \theta < 2$ 。

第三节 估计量的评选标准

一、问题的提出

二、无偏性

三、有效性

四、相合性

五、小结

一、问题的提出

从前一节可以看到, 对于同一个参数, 用不同的估计方法求出的估计量可能不相同, 如第一节的例4和例10. 而且, 很明显, 原则上任何统计量都可以作为未知参数的估计量.

问题

(1) 对于同一个参数究竟采用哪一个估计量好?

(2) 评价估计量的标准是什么?



下面介绍几个常用标准.

二、无偏性

若 X_1, X_2, \dots, X_n 为总体 X 的一个样本,
 $\theta \in \Theta$ 是包含在总体 X 的分布中的待估参数,
(Θ 是 θ 的取值范围)

若估计量 $\hat{\theta} = \theta(X_1, X_2, \dots, X_n)$ 的数学期望
 $E(\hat{\theta})$ 存在, 且对于任意 $\theta \in \Theta$ 有 $E(\hat{\theta}) = \theta$, 则称
 $\hat{\theta}$ 是 θ 的无偏估计量.

无偏估计的实际意义: 无系统误差.

例1 设总体 X 的 k 阶矩 $\mu_k = E(X^k)$ ($k \geq 1$) 存在, 又设 X_1, X_2, \dots, X_n 是 X 的一个样本, 试证明不论总体服从什么分布, k 阶样本矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 是 k 阶总体矩 μ_k 的无偏估计.

证 因为 X_1, X_2, \dots, X_n 与 X 同分布,

故有 $E(X_i^k) = E(X^k) = \mu_k, \quad i = 1, 2, \dots, n.$

即 $E(A_k) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = \mu_k.$

故 k 阶样本矩 A_k 是 k 阶总体矩 μ_k 的无偏估计.

特别的:

不论总体 X 服从什么分布,

只要它的数学期望存在,

\bar{X} 总是总体 X 的数学期望 $\mu_1 = E(X)$ 的无偏估计量.

例2 对于均值 μ , 方差 $\sigma^2 > 0$ 都存在的总体, 若

μ, σ^2 均为未知, 则 σ^2 的估计量 $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$

是有偏的(即不是无偏估计).

证 $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = A_2 - \bar{X}^2,$

因为 $E(A_2) = \mu_2 = \sigma^2 + \mu^2,$

又因为 $E(\bar{X}^2) = D(\bar{X}) + [E(\bar{X})]^2 = \frac{\sigma^2}{n} + \mu^2,$

所以 $E(\hat{\sigma}^2) = E(A_2 - \bar{X}^2) = E(A_2) - E(\bar{X}^2)$

$$= \frac{n-1}{n} \sigma^2 \neq \sigma^2, \text{ 所以 } \hat{\sigma}^2 \text{ 是有偏的.}$$

若以 $\frac{n}{n-1}$ 乘 $\hat{\sigma}^2$, 所得到的估计量就是无偏的.

(这种方法称为**无偏化**).

$$E\left(\frac{n}{n-1} \hat{\sigma}^2\right) = \frac{n}{n-1} E(\hat{\sigma}^2) = \sigma^2.$$

$$\text{因为 } \frac{n}{n-1} \hat{\sigma}^2 = S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

即 S^2 是 σ^2 的无偏估计, 故通常取 S^2 作 σ^2 的估计量.

例3 设总体 X 在 $[0, \theta]$ 上服从均匀分布, 参数 $\theta > 0$, X_1, X_2, \dots, X_n 是来自总体 X 的样本, 试证明 $2\bar{X}$ 和 $\frac{n+1}{n} \max(X_1, X_2, \dots, X_n)$ 都是 θ 的无偏估计.

证 因为 $E(2\bar{X}) = 2E(\bar{X}) = 2E(X) = 2 \times \frac{\theta}{2} = \theta$,
所以 $2\bar{X}$ 是 θ 的无偏估计量.

因为 $X_h = \max(X_1, X_2, \dots, X_n)$ 的概率密度为

$$f(x) = \begin{cases} \frac{nx^{n-1}}{\theta^n}, & 0 \leq x \leq \theta, \\ 0, & \text{其他} \end{cases}$$

所以 $E(X_h) = \int_0^\theta x \cdot \frac{nx^{n-1}}{\theta^n} dx$

$$= \frac{n}{n+1} \theta,$$

故有 $E\left(\frac{n+1}{n} X_h\right) = \theta,$

故 $\frac{n+1}{n} \max(X_1, X_2, \dots, X_n)$ 也是 θ 的无偏估计量.

例4 设总体 X 服从参数为 θ 的指数分布, 概率密度

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0, \\ 0, & \text{其他.} \end{cases}$$

其中参数 $\theta > 0$, 又设 X_1, X_2, \dots, X_n 是来自总体 X 的样本, 试证 \bar{X} 和 $nZ = n[\min(X_1, X_2, \dots, X_n)]$ 都是 θ 的无偏估计.

证明 因为 $E(\bar{X}) = E(X) = \theta$,

所以 \bar{X} 是 θ 的无偏估计量.

而 $Z = \min(X_1, X_2, \dots, X_n)$ 服从参数为 $\frac{\theta}{n}$ 的指数分布,

$$\text{概率密度 } f_{\min}(x; \theta) = \begin{cases} \frac{n}{\theta} e^{-\frac{nx}{\theta}}, & x > 0, \\ 0, & \text{其他.} \end{cases}$$

$$\text{故知 } E(Z) = \frac{\theta}{n}, \quad E(nZ) = \theta,$$

所以 nZ 也是 θ 的无偏估计量.

由以上两例可知,一个参数可以有不同的无偏估计量.

$$Z \sim \text{Exp}\left(\frac{\theta}{n}\right), \quad f_Z(z) = \frac{n}{\theta} e^{-nz/\theta}, \quad z > 0$$

设 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Exp}(\theta)$,

$$f(x; \theta) = \frac{1}{\theta} e^{-x/\theta}, \quad x > 0; \quad F(x) = P(X \leq x) = 1 - e^{-x/\theta}, \quad x > 0.$$

令 $Z = \min(X_1, \dots, X_n)$ 。对任意 $z > 0$, 有

$$\begin{aligned} P(Z > z) &= P(\min(X_1, \dots, X_n) > z) \\ &= P(X_1 > z, \dots, X_n > z) \\ &= \prod_{i=1}^n P(X_i > z) \quad (\text{独立}) \\ &= (P(X > z))^n \\ &= (1 - F(z))^n \\ &= (e^{-z/\theta})^n = e^{-nz/\theta}. \end{aligned}$$

因此

$$F_Z(z) = P(Z \leq z) = 1 - P(Z > z) = 1 - e^{-nz/\theta}, \quad z > 0,$$

对 $z > 0$ 求导得密度

$$f_Z(z) = F'_Z(z) = \frac{n}{\theta} e^{-nz/\theta}, \quad z > 0.$$

这表明

$$Z \sim \text{Exp}\left(\frac{\theta}{n}\right), \quad E(Z) = \frac{\theta}{n} \Rightarrow E(nZ) = \theta.$$

三、有效性

比较参数 θ 的两个无偏估计量 $\hat{\theta}_1$ 和 $\hat{\theta}_2$,如果在样本容量 n 相同的情况下, $\hat{\theta}_1$ 的观察值在真值 θ 的附近较 $\hat{\theta}_2$ 更密集,则认为 $\hat{\theta}_1$ 较 $\hat{\theta}_2$ 有效.

由于方差是随机变量取值与其数学期望的偏离程度,所以无偏估计以方差小者为好.

设 $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$ 与 $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$ 都是 θ 的无偏估计量,若有 $D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$, 则称 $\hat{\theta}_1$ 较 $\hat{\theta}_2$ 有效.

例5 (续例4)

试证当 $n > 1$ 时, θ 的无偏估计量 \bar{X} 较 nZ 有效.

证明 由于 $D(X) = \theta^2$, 故有 $D(\bar{X}) = \frac{\theta^2}{n}$,

又因为 $D(Z) = \frac{\theta^2}{n^2}$, 故有 $D(nZ) = \theta^2$,

当 $n > 1$ 时, $D(nZ) > D(\bar{X})$,

故 θ 的无偏估计量 \bar{X} 较 nZ 有效.

例6 (续例3) 在例3中已证明 $\hat{\theta}_1 = 2\bar{X}$ 和

$\hat{\theta}_2 = \frac{n+1}{n} \max\{X_1, X_2, \dots, X_n\}$ 都是 θ 的无偏估计

量, 现证当 $n \geq 2$ 时, $\hat{\theta}_2$ 较 $\hat{\theta}_1$ 有效.

证明 由于 $D(\hat{\theta}_1) = 4D(\bar{X}) = \frac{4}{n} D(X) = \frac{\theta^2}{3n}$,

$$D(\hat{\theta}_2) = D\left(\frac{n+1}{n} X_h\right) = \left(\frac{n+1}{n}\right)^2 D(X_h),$$

$$\text{又因为 } E(X_h) = \frac{n+1}{n} \theta,$$

$$E(X_h^2) = \int_0^\theta \frac{n}{\theta^n} x^{n+1} dx = \frac{n}{n+2} \theta^2,$$

$$D(X_h) = E(X_h^2) - [E(X_h)]^2$$

$$= \frac{n}{(n+1)^2(n+2)} \theta^2,$$

$$\text{故 } D(\hat{\theta}_2) = \frac{1}{n(n+2)} \theta^2,$$



又 $n \geq 2$, 所以 $D(\hat{\theta}_2) < D(\hat{\theta}_1)$, $\hat{\theta}_2$ 较 $\hat{\theta}_1$ 有效.

四、相合性

若 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 为参数 θ 的估计量,
若对于任意 $\theta \in \Theta$, 当 $n \rightarrow \infty$ 时, $\hat{\theta}(X_1, X_2, \dots, X_n)$
依概率收敛于 θ , 则称 $\hat{\theta}$ 为 θ 的相合估计量.

例如 由第六章第三节知, 样本 $\mathbf{k} (k \geq 1)$ 阶矩是
总体 \mathbf{X} 的 \mathbf{k} 阶矩 $\mu_k = E(\mathbf{X}^k)$ 的相合估计量,
进而若待估参数 $\theta = g(\mu_1, \mu_2, \dots, \mu_n)$, 其中 g 为连续
函数, 则 θ 的矩估计量 $\hat{\theta} = g(\hat{\mu}_1, \hat{\mu}_2, \dots, \hat{\mu}_n) = g(A_1, A_2,$
 $\dots, A_n)$ 是 θ 的相合估计量.

例7 试证：样本均值 \bar{X} 是总体均值 μ 的相合估计量，样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 及样本的二阶中心矩 $B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 都是总体方差 σ^2 的相合估计量.

证明 由大数定律知,

$$\forall \varepsilon > 0, \text{ 有 } \lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| < \varepsilon \right\} = 1,$$

所以 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 是 μ 的相合估计量.

$$\begin{aligned} \text{又 } B_2 &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2) \\ &= \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = A_2 - \bar{X}^2, \\ &\quad (A_2 \text{ 是样本二阶原点矩}) \end{aligned}$$

由大数定律知,

$$A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \text{ 依概率收敛于 } E(X^2),$$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \text{ 依概率收敛于 } E(X),$$

故 $B_2 = A_2 - \bar{X}^2$

依概率收敛于 $E(X^2) - [E(X)]^2 = \sigma^2$,

所以 B_2 是 σ^2 的相合估计量.

又 $\lim_{n \rightarrow \infty} \frac{n}{n-1} = 1$,



所以 $S^2 = \frac{n}{n-1} B_2$ 也是 σ^2 的相合估计量.

五、小结

估计量的评选的三个标准 { 无偏性
有效性
相合性

相合性是对估计量的一个基本要求, 不具备相合性的估计量是不予以考虑的.

由最大似然估计法得到的估计量, 在一定条件下也具有相合性. 估计量的相合性只有当样本容量相当大时, 才能显示出优越性, 这在实际中往往难以做到, 因此, 在工程中往往使用无偏性和有效性这两个标准.

课后作业第10题

设 X_1, X_2, \dots, X_n 为来自总体 X 的一个样本, \bar{X}, S^2 分别为样本均值和样本方差, $E(X) = \mu, D(X) = \sigma^2$ 。

(1) 确定常数 c , 使 $c \sum_{i=1}^{n-1} (X_{i+1} - X_i)^2$ 为 σ^2 的无偏估计;

(2) 确定常数 c , 使 $(\bar{X})^2 - cS^2$ 为 μ^2 的无偏估计。

$$\begin{aligned} \text{解: (1)} \quad E \left[c \sum_{i=1}^{n-1} (X_{i+1} - X_i)^2 \right] &= c \sum_{i=1}^{n-1} \left[E(X_{i+1}^2) - 2E(X_{i+1})E(X_i) + E(X_i^2) \right] \\ &= c \sum_{i=1}^{n-1} \left[(\sigma^2 + \mu^2) - 2\mu^2 + (\sigma^2 + \mu^2) \right] = 2c(n-1)\sigma^2 = \sigma^2, \quad \text{得 } c = \frac{1}{2(n-1)}. \end{aligned}$$

$$\begin{aligned} \text{(2)} \quad E \left[(\bar{X})^2 - cS^2 \right] &= E(\bar{X})^2 - cE(S^2) = D(\bar{X}) + E^2(\bar{X}) - cE(S^2) \\ &= \frac{\sigma^2}{n} + \mu^2 - c\sigma^2 = \mu^2, \quad \text{得 } c = \frac{1}{n}. \end{aligned}$$

4. 设总体 X 的概率密度为

$$f(x; \theta) = \begin{cases} \frac{1}{2\theta}, & 0 < x < \theta, \\ \frac{1}{2(1-\theta)}, & \theta < x < 1, \\ 0, & \text{其他,} \end{cases}$$

其中 $0 < \theta < 1$ 。

设 X_1, X_2, \dots, X_n 为来自总体 X 的简单随机样本, \bar{X} 为样本均值。

(1) 求参数 θ 的矩估计量 $\hat{\theta}$;

(2) 判断 $4\bar{X}^2$ 是否为 θ^2 的无偏估计量, 并说明理由。

解:

(1) 矩估计量:

先求数学期望

$$\begin{aligned} E(X) &= \int_0^{\theta} x \cdot \frac{1}{2\theta} dx + \int_{\theta}^1 x \cdot \frac{1}{2(1-\theta)} dx \\ &= \frac{1}{2\theta} \cdot \frac{\theta^2}{2} + \frac{1}{2(1-\theta)} \cdot \frac{1-\theta^2}{2} \\ &= \frac{\theta}{4} + \frac{1-\theta^2}{4(1-\theta)} = \frac{1+2\theta}{4}. \end{aligned}$$

令 $E(X) = \bar{X}$, 得

$$\frac{1+2\theta}{4} = \bar{X} \Rightarrow \hat{\theta} = \frac{4\bar{X}-1}{2} = 2\bar{X} - \frac{1}{2}.$$

(2) 判断 $4\bar{X}^2$ 是否为 θ^2 的无偏估计量:

计算

$$\begin{aligned} E(X^2) &= \int_0^{\theta} x^2 \cdot \frac{1}{2\theta} dx + \int_{\theta}^1 x^2 \cdot \frac{1}{2(1-\theta)} dx \\ &= \frac{1}{2\theta} \cdot \frac{\theta^3}{3} + \frac{1}{2(1-\theta)} \cdot \frac{1-\theta^3}{3} \\ &= \frac{2\theta^2 + \theta + 1}{6}. \end{aligned}$$

因此

$$\begin{aligned} D(X) &= E(X^2) - (E(X))^2 \\ &= \frac{2\theta^2 + \theta + 1}{6} - \left(\frac{1+2\theta}{4}\right)^2 = \frac{4\theta^2 - 4\theta + 5}{48}. \end{aligned}$$

又

$$\begin{aligned} E(\bar{X}^2) &= D(\bar{X}) + (E(\bar{X}))^2 \\ &= \frac{D(X)}{n} + \left(\frac{1+2\theta}{4}\right)^2 \\ &= \frac{4\theta^2 - 4\theta + 5}{48n} + \frac{(1+2\theta)^2}{16}. \end{aligned}$$

从而

$$\begin{aligned} E(4\bar{X}^2) &= 4E(\bar{X}^2) \\ &= \frac{4\theta^2 - 4\theta + 5}{12n} + \frac{(1+2\theta)^2}{4} \neq \theta^2. \end{aligned}$$

因此, $4\bar{X}^2$ 不是 θ^2 的无偏估计量。